

能找到原文证据，仍需核对口径

默认混合检索经 10 题人工复核：7 题证据充分、3 题部分回答、0 题错误。判断基于完整摘录，非首条结果。明确公司与单项指标时较好；全景比较仍会漏项、混入其他期间或口径。

12 份完整年报 / 3,265 页 / 17,474 个检索块 / 2,607 张提取表

01 三种检索方式的实际表现

方法	规范页命中	MRR	自动数字覆盖
BM25 关键词	74.2%	0.415	90.8%
BGE 语义向量	50.0%	0.208	69.2%
RRF 混合检索	60.0%	0.335	91.7%

指标均为 10 题宏平均。“规范页命中”只检查指定来源页，不代表全部相关证据召回；MRR 衡量首次规范证据排名；“数字覆盖”是自动字符串检查，不是人工正确率。仅混合检索有人工作答核验；小样本不外推至所有财报问题。

02 哪里有效

单公司、指标名称明确的数字题较稳。公司过滤缩小范围，保留表格行列、单位和年份后，可回到原页核验。Q01-Q06、Q08 的完整摘录证据足以作答；部分题需联合多条证据。

03 哪里翻车

Q07 混入季度相关片段，未形成干净的年度回答。Q09 全景题仅 3 家完整、5 家部分、4 家缺失；Q10 按集团口径仅 5 家完整、3 家部分、4 家缺失。南京银行 0.80% 属母公司口径，是真实值但不能当成集团答案。

04 为什么

本题集以精确财务名词为主，BM25 关键词的规范页命中最高；语义相近不保证年份、单位与口径正确。全景每家只取 2 块，多层表头和重复披露会占用名额。RRF 融合也可能把含正确证据的候选排后。

05 下一轮直接改这三件事

1. 先按公司、年度、集团/母公司、单位规范化指标，再生成答案；冲突时并列原文，不自动选值。
2. 全景题逐公司补检索：扩大候选池，按“公司 × 指标”检查覆盖，缺失项明确标出。
3. 加入表头与跨页表衔接、相关性重排；扩充人工题集，分别评估数值、单位、期间和口径。

真实 512 维 BGE-small-zh 向量 + BM25 + RRF；回答为检索原文摘录，未使用生成式大模型。普通题 Top-10；2 道全景题逐公司 Top-2。
未做图片 OCR；跨页表未自动合并；跨公司单位与财务口径未自动统一。表格为 PDF 提取结果，仍须查看原表。